第 10 章 医疗大模型的评测与基准

在大规模语言模型（LLMs）迅猛发展的浪潮中，医疗健康领域被公认为最具变革潜力的应用场景之一。然而，医疗垂直领域的严谨性、专业性以及对生命安全的极高敏感性，决定了通用领域的模型评测范式无法直接迁移至医疗场景。早期的评测主要集中在基础的自然语言处理（NLP）指标上，如精确率、召回率和 F1 分数，但这些指标仅能反映模型在特定任务（如实体识别、摘要提取）上的字面拟合程度，难以评估其在处理动态临床工作流和复杂医学推理时的真实能力。随着技术的演进，评测范式开始向“医学执业化”靠拢，涌现出一批以执业医师资格考试为蓝本的知识基准测试集。

当前，医疗大模型的评估正处于一个关键的转型期：从简单的知识回顾测试（Knowledge Retrieval）迈向深度的临床能力验证。这一演变不仅反映了模型能力的提升，也体现了业界对 AI 医疗风险认识的深化。一方面，模型在 MedQA、PubMedQA 等标准化考试上的表现已逐渐饱和，甚至在多项指标上超越了人类专家，这被称为“考试分数幻觉”；另一方面，模型在处理真实世界电子健康档案（EHR）、医患对话以及多模态医学影像分析时，仍面临幻觉频发、鲁棒性不足以及伦理偏差等深层次挑战。本章将详细梳理医疗大模型评测的现状与前沿趋势，旨在建立一个从理论知识到临床实践、从技术指标到人类感知的全方位评价体系。

10.1 常见的医疗考试评测集

医学知识评测是衡量医疗大模型专业素质的第一道门槛。这些评测集通过模拟医学教育与评价体系中的标准化考试，量化模型对医学事实、病理机制、药物知识以及诊断逻辑的掌握程度。目前的评测集可以从数据来源、语言覆盖、任务难度以及评价维度四个方面进行系统分类。

10.1.1 国际主流执业考试基准：MedQA、MedMCQA 与 PubMedQA

在全球范围内，MedQA 是公认的最具权威性的医学问答基准之一。其核心内容源自美国执业医师资格考试（USMLE），题干通常为一段详细的临床病例描述（Clinical Vignette），涵盖患者的主诉、家族史、体格检查、实验室化验结果以及影像学报告。MedQA 包含约 12,723 个多选题，要求模型在四个或五个选项中选出唯一正确答案。这种评测不仅测试模型的医学常识，更测试其在复杂信息干扰下的鉴别诊断能力。最新的评测数据显示，Google 的 Med-Gemini 模型通过引入不确定性引导的搜索策略，在 MedQA 上达到了 91.1% 的准确率，而 OpenAI 的推理模型 o1 则达到了 96.5%，标志着医学知识储备已进入“超专家级”水平。

MedMCQA 则是目前规模最大的医学多选题数据集之一，涵盖了超过 193,000 个来自印度研究生医学入学考试（AIIMS/NEET-PG）的问题。与 MedQA 相比，MedMCQA 的题干通常更为简洁，但涉及的主题极广，覆盖了解剖学、药理学、病理学等 21 个医学分支及 2,400 多个细分主题。该数据集对评估模型的知识广度和跨学科迁移能力具有不可替代的价值。

PubMedQA 则开辟了另一条评测路径，即“证据支持下的医学推理”。该数据集基于真实的 PubMed 摘要，要求模型回答专家标注的科研问题，答案分为“Yes”、“No”或“Maybe”三类。PubMedQA 考察的是模型对前沿医学文献的阅读理解能力，尤其是能否根据摘要中的实验数据得出正确的结论。在这一基准上，Med-PaLM 2 在自洽性增强提示策略下达到了 81.8% 的准确率，显示出模型在辅助科学研究方面的潜力。

下表总结了目前国际主流医疗考试评测集的关键参数与 SOTA（当前最优）表现：

表 10.1: 全球主流医疗考试评测集对比表

基准名称	数据来源	题目规模	主要任务	SOTA 模型表现
MedQA	USMLE 风格考试	12,723	临床病历诊断	OpenAI o1 (96.5%)
MedMCQA	AIIMS / NEET-PG	193,000+	跨学科知识检索	Med-PaLM 2 (72.3%)
PubMedQA	生物医学摘要	1,000 (专家标)	科学文献推理	Med-Gemini (81%+)
MMLU-Med	多学科混合	约 3,000 (子集)	基础医学问答	GPT-4o (88.7%)

10.1.2 中文医学基准的崛起：CMExam、CMB 与 MedBench

由于医学实践具有极强的地域性和文化属性，特别是中医药体系的存在，使得仅依靠英文基准测试难以全面评价中文环境下的模型表现。近年来，中国学术界开发了一系列具有中国特色的医学评测集。

CMExam 是最具代表性的中文执业考试数据集，题目全部源自中国国家执业医师资格考试（NMLE）。该数据集包含超过 60,000 道多选题，并由医学专家根据 ICD-11 标准对每一道题进行了细粒度的标注，包括科室、疾病组别以及能力水平。研究显示，尽管 GPT-4 在英文 MedQA 上表现优异，但在 CMExam 上的表现却相对受限（约 61.6%），这反映了中外执业准则、术语表达以及用药习惯的显著差异。

CMB（Comprehensive Medical Benchmark in Chinese）则由香港中文大学（深圳）等机构推出，旨在构建一个覆盖全科室、全专业层级的综合评测平台。CMB 包含 28 万道题目，除了临床医学外，还专门设置了中医、口腔医学和护理学等模块。其 CMB-Clin 部分包含 74 个复杂的临床咨询案例，要求模型在不完整的病史描述下进行多轮对话，模拟真实的挂号、分诊和问诊过程。

MedBench（上海交通大学/人工智能实验室）则进一步推向了系统化。其 v4 版本汇聚了超过 70 万个专家策划的任务，涵盖了医学语言理解、生成、知识问答、复杂推理及安全性与伦理五大维度。MedBench 的创新之处在于其“云端自动评测”与“动态题库机制”，通过物理隔离题目与模型，并对选项进行循环洗牌，有效防止了模型通过记忆训练集答案来“刷分”的作弊行为。

10.1.3 知识评测的深度反思：为什么“刷题高分”不再能说服临床医生？

随着模型在各类考试中屡创新高，评测的局限性也日益突显。学术界开始质疑这种静态问答形式对实际临床能力的代表性。其核心症结在于“知识-实践鸿沟”：

第一，临床信息的稀疏性与模糊性。考试题干中的信息往往是“净化过”的——所有化验指标都是准确的，主诉逻辑清晰。然而在临床实战中，患者往往提供误导性的症状描述，检查结果可能存在偏差，医生需要具备从海量噪声中提炼关键信号的“临床直觉”，而考试题集对此缺乏考察。

第二，数据污染与模型记忆。由于 MedQA、CMExam 等数据集在互联网上广泛流通，它们很可能已经通过各种途径进入了大模型的训练语料库。这种“开卷考试”导致模型分数虚高。最新的会员推理攻击（MIA）研究显示，某些模型在已知训练数据上的表现比未见数据高出 10%-20%，严重影响了评测的公正性。

第三，缺乏后果加权。在考试中，答错一道感冒题和答错一道急性心肌梗死题扣分是相同的。但在临床中，后者的错误是致命的。目前的考试基准缺乏对模型建议安全等级的量化，这直接导致了模型在通过“智力测试”的同时，可能在实际应用中释放出不可控的安全隐患。

10.2 超越做题：如何评估模型的临床安全性与医生采纳度？

当医疗大模型脱离了受控的考试环境，进入复杂的医疗社会技术系统（Sociotechnical System）时，评测的重心必须从“正确性”转向“安全性”、“可靠性”与“人类协作效能”。这需要构建一套多维度、多主体的综合评估框架。

10.2.1 临床安全性评估：从“负面清单”到“红队测试”

临床安全性评估的核心是界定模型输出的风险边界。目前，最具代表性的框架是临床安全性-有效性双轨基准（CSEDB）。该框架由 32 位资深医师通过德尔菲法（Delphi Method）建立，旨在通过“安全性大门”对模型输出进行一票否决制评估。

CSEDB 包含 17 项关键安全指标，主要集中在以下四个极高风险领域：

1. **危急重症误诊（S-01, S-02）：**评估模型是否忽略患者可能存在心源性休克、主动脉夹层等危及生命的关键预警信号。

2. **药物管理差错（S-03, S-06, S-09）：**评估模型是否给出绝对禁忌药物、错误化疗剂量，或忽视患者严重过敏史等高危用药风险。
3. **临床逻辑幻觉（S-11, S-12）：**评估模型在生成出院摘要或手术记录时，是否凭空捏造并不存在的检查数值、既往手术史等关键信息。
4. **伦理行为失当（S-10, S-16）：**评估模型在面对高风险心理行为或公共健康议题时，是否给出不当鼓励性表述，或传播反疫苗等错误健康信息。

研究结果表明，医疗专用微调模型（如 MedGPT）在这些安全指标上显著优于通用模型，其安全性评分领先约 19.8%，且在处理致命药效反应（S-06）等场景时能达到接近 1.0 的完美得分。这说明医学对齐（Medical Alignment）不仅仅是知识的灌输，更是对模型“禁忌行为”的强化。

10.2.2 医疗幻觉的分类与防御机制评估

幻觉是 LLM 在临床应用中的顽疾。在医疗场景下，幻觉的表现形式更为隐蔽且危害更大。学术界通常将医疗幻觉解构为五个主要簇类：

1. **事实性幻觉：**模型虚构医学概念、文献引用或统计数据。
2. **因果性幻觉：**模型虽能正确识别症状，但错误推断病理生理路径。
3. **时序性幻觉：**在处理纵向病历时，模型混淆症状发生的先后顺序或药物调整的时间节点。
4. **模态失配幻觉：**在多模态任务中，模型生成的描述与影像学表现（如 X 光片中的实际病灶）不一致。
5. **推断性幻觉：**在病史不完整时，模型过于武断地补全未知的临床细节。

为了评估模型对幻觉的抵御能力，MedHallBench 等基准引入了“诚实度测试”——在问题没有明确答案或存在误导性前提时，模型是否能够诚实地回答“我不知道”或纠正错误的前提。实验证明，引入思维链（CoT）推理可将 Gemini-2.5 Pro 等模型的幻觉率相对降低 10%-15%，因为显性的推理路径允许模型进行内部校验。

10.2.3 医生采纳度与人机协同效能评估

即便模型具备卓越的智力，如果其交互体验差或增加了医生的认知负荷，它也将面临“采纳僵局”。评估医生采纳度需结合主观量表与客观绩效指标。

10.2.3.1 主观体验评估：SUS 与 PDSQI-9 指标

系统易用性量表（SUS）是评估医疗软件的通用工具。在针对 AI 抄写员（AI Scribe）的研究中，临床医生对 LLM 辅助系统的 SUS 评分平均为 65.7，处于“合格但非优秀”的区间。针对临床文档摘要任务，学术界进一步开发了 PDSQI-9（Provider Documentation Summarization Quality Instrument）工具，从准确性、完整性、简洁性、实用性等 9 个维度进行专家评审。值得注意的是，通过对比“LLM 作为评委”与人类专家的评分，发现顶级模型（如 GPT-o3-mini）在 PDSQI-9 上的评分一致性（ICC）已达到 0.818，这为低成本、高频次的文档质量自动化审计提供了可能。

10.2.3.2 客观效能评估：工作流整合与“睡衣时间”追踪

评估大模型采纳度的最终指标是其对医疗生产力的真实提升。关键指标包括：

1. **任务完成时间（Time-to-complete）：**评估在 AI 辅助模式下，医生撰写出院小结或回复患者咨询的用时缩短比例。现有研究显示，在肿瘤会诊场景中，AI 辅助可使病历准备速度提升约 21.4%。
2. **修改率与纠错负担：**评估医生在 AI 初稿上进行删除、增加或修正的字符比例。若修改率超过 30%，模型可能被视为“额外负担”而非“辅助工具”。
3. **“睡衣时间”减少：**该指标用于衡量 AI 是否减少医生在下班后（所谓“睡衣时间”）补录病历的时间量，具有较高临床价值。大规模调研显示，使用环境 AI 语音助手可使医生的倦怠感降低 40%。

10.2.4 监管合规性与全球公平性评测

随着医疗大模型被纳入监管，合规性评估成为了准入的前提。FDA 对 SaMD 的审查重点已转向其生命周期管理（TPLC）和预先定义的变更控制计划（PCCP）。在评测中，必须包含针对特定族群、性别和年龄的偏见测试。最新的 MedQA-Bias 评测显示，某些顶级模型在面对特定种族标签（如非裔、亚裔）的病例时，诊断建议的保守程度和准确率存在统计学上的显著差异，这种“算法偏见”是临床部署中的重大隐患。

下表整理了超越单纯考试的临床多维评估维度：

表 10.2: 医疗大模型临床综合评测维度框架

评估维度	核心指标 / 工具	评估主体	临床应用意义
临床安全性	CSEDB 17 项指标	医学专家红队	识别用药禁忌、漏诊风险等致命错误
文档质量	PDSQI-9, ROUGE	高级医师	确保病历摘要的专业性与可读性
工作流效能	任务完成时间对比	临床一线医生	衡量是否真正减少行政负担，缓解倦怠
幻觉抗性	MedHallu, F1-Score	自动化评测	评估模型在不确定情况下的诚实度
公平性与伦理	MedEthicsQA, 偏见	伦理审查委员会	防止算法对弱势群体产生歧视性建议

10.2.5 面向未来的动态交互式评测：AgentClinic 与多模态推理

评测体系正朝着更加真实的方向进化。AgentClinic 等新一代评测环境将 LLM 置于一个交互式的虚拟诊室中。在这些环境中，模型不再是接收完整信息的“答题者”，而是需要主动向虚拟病人提问、要求化验单、解释检查结果并最终给出治疗方案的“医生代理人”。初步研究显示，许多在静态考试中获得 90 分以上的模型，在这种动态问诊环境下的诊断准确率会跌至 60% 以下，这揭示了模型在信息采集能力上的严重缺失。

此外，随着 Med-Gemini 等原生多模态模型的出现，评测也必须包含跨模态推理。例如，要求模型结合心电图波形、影像学扫描以及文字病历共同给出一份危急值通报，这种多源证据融合（Cross-modal Fusion）的能力将是未来医疗大模型评测的制高点。

10.3 展望：构建以生命安全为中心的评测生态

医疗大模型的评测已走过了单纯依靠考试分数的“刷题阶段”，正在构建一套以“临床安全为核心、人机协同为基准、真实世界证据为支撑”的动态生态系统。评测基准不再是一个静态的数字，而是一套持续迭代的质量控制体系。

未来的发展趋势将聚焦于以下三点：首先是评测指标的“价值加权”，赋予涉及生命安全的错误极高的权重；其次是评测过程的“透明化”，强调模型推理路径（Rationale）的可解释性评估；最后是评测场景的“社会技术化”，将 AI 视为医疗团队的一个特殊成员，评估其如何影响医患沟通、诊疗成本以及社会公正性。通过这些多维度的严苛考量，医疗大模型才能真正从算法实验室迈向临床实战，成为守护人类健康的可靠伙伴。