第 17 章 医学伦理与算法偏见

医疗大模型本质上并不是冰冷客观的医学真理发生器，而是对人类历史临床行为、医学文献积累以及社会结构语言的高度统计学浓缩。如果这些蕴含着百亿级参数的庞然大物未能经过审慎的伦理对齐与纠偏处理，大模型非但不能成为抹平医疗鸿沟、推进健康平等的科技利器，反而会异化为一部隐蔽且高效的“偏见放大器”。它们会将深藏于人类社会结构深处、长期存在的医疗资源分配不均与歧视性观念，冷酷地固化在不透明的黑盒算法之中，以一种看似客观理性的面目继续侵蚀医学的公平正义。

17.1 算法偏见：大模型是否会加剧医疗资源的不平等？

17.1.1 偏见的系统性放大器效应

算法偏见（Algorithmic Bias）在数字健康领域，特指由于模型训练数据的系统性偏差或算法设计逻辑的缺陷，导致人工智能在面对不同社会经济地位、种族、民族、宗教信仰、性别特征、地域分布或残疾群体时，表现出显著差异化的预测性能和决策倾向，进而加剧系统性健康不平等的现象。在人工智能被广泛宣传为解决医疗资源短缺、实现降本增效的技术解决方案的当下，如果忽视算法偏见这一潜在风险，医疗大模型不仅无法缓解现实世界中的医疗资源不均衡，反而可能在数字空间中复制甚至放大既有的不公平结构。因此，理解算法偏见的生成机制与社会影响，已经成为医疗人工智能伦理研究的核心议题之一。

从技术角度来看，算法偏见的根源首先来自训练数据本身的结构性失衡。现代医疗人工智能系统通常依赖大规模历史医疗数据进行训练，而这些数据往往并不能代表真实世界的完整人口结构。例如，在许多医学影像数据库中，数据样本主要来自少数大型城市医院，而来自基层医疗机构、农村地区或发展中国家的病例数量则相对有限。这种数据来源的集中化，会导致模型在主流人群上表现良好，却在少数群体中出现明显性能下降。类似问题也出现在性别与年龄结构中。例如，一些心血管疾病预测模型由于训练数据中男性患者比例过高，在女性患者群体中的预测准确率明显降低。此外，在皮肤病识别模型中，如果训练数据主要来自浅色皮肤人群，模型在深色皮肤人群中的诊断准确率就可能显著下降。这种数据偏差在传统统计学模型中已经存在，而在深度学习模型中，由于模型参数规模巨大、学习能力更强，这种偏差往往会被进一步强化，从而形成系统性的算法偏见。

除了数据来源问题之外，算法设计本身也可能在无意中放大社会结构性差异。许多医疗 AI 系统在优化过程中以整体预测准确率或平均损失函数作为目标，这种单一指标优化策略可能掩盖不同群体之间的性能差异。例如，一个模型在总体上达到 90% 的准确率，但如果其中某些弱势群体的准确率仅为 70%，这种不平衡仍然可能被整体指标所掩盖。在实际临床环境中，这种“平均意义上的准确”并不能保证公平性，反而可能使弱势群体承担更高的误诊风险。此外，一些模型在设计时使用代理变量（Proxy Variables）来替代难以获取的医学信息，例如使用医疗费用或医疗资源使用频率作为健康风险指标。然而，这些代理变量往往与社会经济地位高度相关，从而使模型在无意中将贫困群体或医疗资源匮乏地区的人群低估为低风险患者。这种现象曾在多个医疗风险预测系统中被发现，表明算法偏见不仅源于数据问题，也可能嵌入在模型设计逻辑之中。

更为复杂的是，算法偏见在医疗大模型时代呈现出“系统性放大器”的效应。传统医疗决策通常由医生个体完成，其影响范围相对有限；而在大模型驱动的医疗系统中，单一算法可能被部署在成千上万家医疗机构之中，从而在更大规模上影响诊疗决策。一旦模型内部存在偏见，这种偏差就可能被迅速复制并扩散。例如，在医疗资源分配系统中，如果风险评估模型系统性低估某些群体的疾病严重程度，那么这些患者在医疗资源分配过程中可能持续处于不利地位，从而形成“技术强化的不平等”。此外，算法还可能在长期使用中形成反馈循环：如果模型预测某一群体患病风险较低，医疗系统可能减少对该群体的筛查与检测，从而进一步减少相关数据的积累；在下一轮模型训练中，由于数据缺失，模型可能继续维持这一偏差。通过这种循环机制，算法偏见不仅不会自然消失，反而可能在时间维度上不断加剧。

从伦理与社会治理的角度来看，算法偏见问题迫使研究者重新审视医疗人工智能的价值目标。传统医学伦理强调“公平原则”（Justice），即医疗资源的分配应尽可能避免对特定群体产生系统性不利影响。然而，如果医

疗 AI 系统在设计与部署过程中缺乏公平性评估机制，就可能违背这一基本伦理原则。因此，近年来越来越多的研究开始探索“公平机器学习”（Fairness in Machine Learning）在医疗领域的应用，例如通过引入群体公平指标（Group Fairness Metrics）、对抗性去偏训练（Adversarial Debiasing）以及再加权采样（Re-weighting Sampling）等方法来减少算法偏差。同时，在制度层面，一些国家的监管机构也开始要求医疗 AI 系统在上线前进行公平性评估，并公开不同人群之间的性能差异。这些努力表明，算法偏见并非无法解决的问题，但其治理需要技术创新、伦理规范与政策监管三方面的协同推进。

综上所述，算法偏见是医疗人工智能发展过程中不可忽视的结构性挑战。如果缺乏有效的识别与干预机制，医疗大模型很可能在数字空间中复制并强化现实社会中的健康不平等。然而，通过更加多样化的数据采集策略、更加公平的算法设计以及更加严格的伦理与监管框架，医疗 AI 仍然有可能成为促进医疗公平的重要工具。未来医疗人工智能的发展，不仅需要追求更高的预测准确率，更需要在技术进步与社会公平之间建立新的平衡。

17.1.2 底层数据表征的“结构性缺席”

大模型产生系统性偏见的根本原因，往往并不在于算法本身，而在于其赖以训练的底层数据结构存在严重失衡。人工智能系统的行为模式，本质上是对历史数据统计规律的抽象表达。当训练数据在地域分布、社会结构或疾病谱上呈现出明显倾斜时，模型所学习到的知识结构也会随之产生偏差。当前大多数医疗基础大模型的训练语料，主要来自发达国家的科研型医疗机构、大型城市医院以及高度标准化的公共医学数据库。例如，美国的 MIMIC（Medical Information Mart for Intensive Care）数据库、英国生物样本库（UK Biobank）以及多个欧美国家的医学影像开放数据集，构成了当代医学机器学习研究的重要数据来源。这些数据库在数据规模与质量上无疑具有极高价值，但其样本来源却往往集中于特定地区、特定人群以及特定医疗体系。这种数据分布结构在无形中塑造了模型的“基准人类模型”（Default Human Model）：一个主要由城市居民、接受过规范医疗服务、并且能够进入大型医疗机构体系的人群所构成的统计画像。

这种结构性的样本偏差意味着，大量处于医疗体系边缘的人群在训练数据中几乎处于“缺席状态”。在全球范围内，农村地区患者、少数民族群体、低收入家庭以及中低收入国家（Low- and Middle-Income Countries, LMICs）居民的医疗数据往往难以被系统性收集与共享。一方面，这些地区的医疗信息化水平相对较低，电子病历系统尚未全面普及；另一方面，由于科研资源集中在少数顶级医疗中心，大量基层医疗机构的数据并未进入公共研究数据库。这种结构性缺席导致模型在训练阶段无法充分学习这些人群的疾病特征与诊疗模式。例如，在一些基于欧美数据训练的疾病预测模型中，模型往往更擅长识别发达国家常见疾病谱，而对发展中国家高发的传染性疾病或环境相关疾病缺乏有效识别能力。同样，在医学影像模型中，如果训练样本主要来自高端医疗设备生成的数据，那么模型在面对低分辨率设备或不同扫描参数下生成的影像时，性能可能会明显下降。

语言与知识体系的偏差也是数据结构失衡的重要来源。当前绝大多数医学文献和临床指南以英语为主要语言发表，这使得医学知识库在语言层面呈现出明显的不均衡结构。医疗大模型在训练过程中通常会大量吸收这些英语医学文献，因此其知识结构更容易反映西方医学研究的重点领域。例如，在肿瘤学、心血管疾病以及基因组医学等研究投入较大的领域，模型往往具备较为完善的知识体系；而在热带疾病、地方性流行病以及某些传统医学领域，模型可能缺乏足够的知识储备。此外，不同国家的诊疗指南和医疗实践存在差异，例如药物使用规范、疾病筛查策略以及医疗资源配置模式等。如果模型主要依赖单一国家或地区的医学文献进行训练，其在跨区域应用时可能会出现知识迁移失效的问题。这种知识结构的不平衡，使得医疗大模型在全球应用场景中难以保持一致的可靠性。

结构性缺席不仅影响模型性能，还可能在医疗决策过程中产生连锁反应。当某些人群在训练数据中长期缺乏代表性时，模型在预测这些群体的健康风险时往往具有更高的不确定性。然而，在实际应用中，这种不确定性往往不会被清晰呈现给医生或患者，模型输出仍然以确定性的形式出现。这意味着，弱势群体不仅在医疗资源获取方面处于不利地位，还可能在数字医疗系统中承担更高的误诊风险。此外，如果医疗机构开始依赖 AI 系统进行资源分配或风险评估，那么这种数据偏差可能进一步影响医疗资源配置。例如，在疾病筛查模型中，如果模型对某些群体的风险评估偏低，医疗系统可能减少对这些群体的筛查力度，从而进一步减少相关数据的积累，形成一种负向反馈循环。

因此，解决底层数据结构失衡问题，已经成为医疗人工智能公平性研究的重要方向。近年来，一些研究者开始推动更加多样化的数据采集策略，例如通过跨国医疗合作项目收集不同人群的数据，或通过公共卫生项目提升发展中国家的医疗数据基础设施。同时，机器学习领域也提出了多种缓解数据偏差的方法，例如通过再加权训练（Re-weighting）、迁移学习（Transfer Learning）以及领域自适应（Domain Adaptation）等技术，使模型能够在有限数据条件下更好地适应不同人群。此外，一些研究还尝试通过生成模型扩充少数群体样本，从而在训练阶段缓解数据不平衡问题。尽管这些方法仍处于探索阶段，但它们表明，医疗大模型的发展不仅是技术问题，更是数据治理与全球健康公平问题。只有在数据来源更加多样化、知识体系更加包容的前提下，医疗人工智能才能真正服务于全体人类，而不是仅仅反映少数群体的健康经验。

17.1.3 代理指标谬误与语言变体歧视

在医疗人工智能的发展历程中，最隐蔽且最危险的算法偏见之一，往往披着理性化数据分析的外衣而存在。许多医疗 AI 系统在设计之初并未直接利用种族、社会阶层或文化背景等敏感变量，而是通过一些看似客观、中立的“代理指标”（Proxy Variables）来间接估计患者的健康风险或医疗需求。然而，当这些代理变量与社会结构性不平等高度相关时，模型就可能在无意中继承甚至强化现实世界中的社会偏见。著名的美国医疗资源分配算法案例便深刻揭示了这一问题。在该系统中，算法设计者为了预测患者未来的健康风险，选择使用“历史医疗支出总额”作为关键指标，并据此筛选出需要进入高风险慢病管理计划的患者。从统计学角度看，医疗支出似乎是一个合理的健康风险代理变量，因为理论上健康状况越差，医疗费用往往越高。然而，美国社会长期存在的医疗资源不平等结构使这一指标产生了严重偏差。由于非裔美国患者在医疗体系中的可及性较低，即使在疾病严重程度相同的情况下，他们的医疗支出往往仍然低于白人患者。因此，当模型以医疗支出作为风险指标时，它实际上将“获得医疗资源的能力”误当成了“真实健康风险”的反映，从而系统性低估了非裔患者的疾病负担。

这一代理指标谬误的后果极为严重。研究人员在对该算法进行事后审计时发现，在符合项目筛选门槛的患者群体中，非裔患者的真实慢性疾病负担平均比同组白人患者高出约 26.3%。换言之，如果系统按照公平原则进行筛选，本应有更多非裔患者进入高风险健康管理计划，但由于算法偏见，这些患者被错误排除在外。这一案例表明，算法偏见并不一定来自直接的种族变量，而往往隐藏在看似合理的代理变量之中。当模型在大规模医疗系统中被广泛部署时，这种偏差将被持续复制，从而在制度层面固化医疗资源的不平等分配。更为复杂的是，由于代理变量通常在统计意义上具有一定预测能力，因此其偏见往往难以在传统模型评估指标中被识别。例如，一个基于医疗支出的风险预测模型在整体预测准确率上可能表现良好，但在不同族群之间却存在显著的不公平性。由此可见，仅依赖传统性能指标评估医疗 AI 系统是远远不够的，公平性评估必须成为算法设计的重要组成部分。

随着生成式人工智能和大型语言模型的兴起，算法偏见问题又在新的维度上表现出来。与传统结构化数据模型不同，大语言模型的知识来源往往是海量互联网文本与医学交流语料，这些文本本身就包含大量社会文化偏见。当模型通过自监督学习吸收这些语言模式时，其中隐含的刻板印象也可能被一并学习。例如，在某些研究中，研究人员发现大型语言模型在生成职业描述时，会将某些少数族裔群体与低收入职业或负面社会标签进行关联。这种语言偏见在医疗场景中尤为敏感，因为医疗交流不仅涉及疾病诊断，还涉及对患者的情绪支持与信任建立。如果模型在语言生成过程中表现出隐含的社会偏见，就可能对医患关系产生负面影响。

在语言层面，方言与语言变体歧视（Dialect Bias）已经成为医疗 AI 研究的重要议题之一。研究表明，一些主流语言模型在处理带有非裔美国英语（African American English, AAE）特征的文本时，会表现出明显的语义理解偏差。例如，当模型分析带有 AAE 语法结构的患者描述时，其情绪分析结果更容易被错误判定为负面或攻击性语言。在医疗对话系统中，这种偏差可能导致系统对特定患者群体的语言表达产生误判。例如，一个心理健康咨询机器人如果将患者的语言误解为敌意或不合作行为，可能在回复中表现出不恰当的冷漠态度，从而影响患者的信任感。此外，一些研究还发现，语言模型在处理具有文化特定表达方式的症状描述时，可能难以准确识别其医学含义。例如，在某些文化语境中，人们可能使用隐喻或非医学术语描述身体不适，而训练数据缺乏这些表达方式的模型可能无法正确理解这些症状信息，从而影响诊断建议的准确性。

更为深远的问题在于，当医疗大模型被嵌入到智能问诊系统、心理健康辅助机器人或虚拟医生助手等应用

场景中时，这些语言偏见可能被大规模复制。如果系统在面对特定语言群体时表现出较低的理解能力或较差的交互质量，那么这些患者在数字医疗服务中的体验将明显劣于其他群体。这不仅会削弱医疗 AI 系统的社会公平性，还可能进一步扩大医疗服务的数字鸿沟。因此，在设计医疗语言模型时，研究者需要格外关注训练语料的多样性与文化代表性，并通过专门的公平性评估工具检测语言偏见。例如，一些研究提出通过构建多语言、多方言的医学对话数据集来提升模型对不同语言群体的适应能力，同时利用对抗训练或偏见校正算法减少模型对特定语言模式的负面关联。

综上所述，代理指标谬误与语言变体歧视揭示了医疗人工智能中两种高度隐蔽的偏见机制：一种来自结构化数据中的代理变量选择，另一种来自自然语言语料中的文化偏见。二者共同说明，算法偏见不仅是技术问题，更是社会结构在数字空间中的投影。如果缺乏严格的伦理审查与技术纠偏机制，医疗 AI 系统可能在不知不觉中复制甚至强化既有的不平等。因此，在未来医疗大模型的研发过程中，必须将公平性审计、数据多样性建设以及跨文化语言理解能力纳入核心技术指标，从而确保人工智能真正成为促进医疗公平的工具，而不是新的不平等放大器。

17.1.4 全生命周期的公平性审计架构

面对医疗人工智能中不断浮现的算法偏见问题，仅仅依靠模型上线后的局部修补或被动纠错显然远远不够。医疗 AI 系统的影响范围往往覆盖大规模患者群体，一旦偏见被嵌入模型结构之中，其影响可能在临床系统中被持续复制并放大。因此，应对这一复杂伦理挑战的关键，在于建立覆盖模型设计、训练、评估与部署全过程的系统性治理机制，即所谓的“全生命周期公平性审计架构”（Lifecycle Fairness Auditing Framework）。这一框架强调，将公平性原则从事后评估转变为前置设计目标，使其成为医疗大模型研发流程中的核心约束条件，而非附属指标。换言之，公平性不应被视为一个可选的优化方向，而应当成为医疗人工智能系统可靠性与安全性的重要组成部分。

在模型研发的早期阶段，公平性治理首先体现在数据采集与数据治理环节。医疗大模型的训练数据往往来自多种来源，包括电子病历系统、医学影像数据库、公共卫生调查以及学术研究语料。如果数据收集阶段本身存在群体代表性不足的问题，那么后续的模型训练过程将不可避免地继承这种结构性偏差。因此，在数据采集与数据预处理阶段，研究者需要主动引入群体代表性评估机制。例如，可以通过人口统计学分析评估训练数据中不同年龄、性别、族群以及地域群体的比例，并在发现明显不均衡时通过数据补充、再加权采样或跨机构数据合作等方式进行修正。此外，医疗数据标注过程同样需要进行伦理审查，因为标注者的主观判断也可能引入潜在偏见。为此，一些研究机构开始建立多元化的标注团队结构，将来自医学、公共卫生、社会学以及伦理学领域的专家共同纳入数据治理流程，以减少单一视角带来的偏差风险。

在模型训练与对齐阶段，公平性问题同样需要被系统性纳入技术设计。近年来，大模型的训练不仅依赖预训练数据，还大量依赖人类反馈强化学习（Reinforcement Learning from Human Feedback, RLHF）等对齐技术来塑造模型行为。然而，如果参与反馈评估的人群结构过于单一，那么模型可能会在价值判断与语言表达上倾向于某一文化或社会群体。因此，在 RLHF 阶段，应当引入更加多样化的人类反馈来源，使模型能够接触到不同文化背景和社会经验的评价标准。此外，在模型优化过程中，可以通过引入公平性约束损失函数（Fairness-aware Loss Functions）来限制模型在不同群体之间的性能差异。例如，在训练阶段同时优化总体预测准确率与群体公平指标，使模型在不同人口子群体中的表现保持相对均衡。通过这种方式，公平性不再是独立的评估维度，而是直接嵌入模型学习目标之中。

当模型进入实际部署阶段时，公平性治理仍然需要持续进行。医疗 AI 系统在真实世界中的运行环境往往与训练数据环境存在差异，这种差异可能随着时间不断扩大，从而导致所谓的“算法漂移”（Algorithmic Drift）。例如，某一地区的人口结构变化、疾病谱变化或医疗政策调整，都可能影响模型预测的准确性与公平性。因此，在临床部署后，医疗 AI 系统必须建立持续监测机制，对模型在不同群体中的表现进行定期评估。这一过程通常依赖于“漂移检测”（Drift Detection）技术，通过统计分析模型输入数据分布与输出结果变化，及时发现潜在偏差。如果系统检测到某些群体的预测误差显著增加，则需要启动再训练或参数调整流程，以避免偏差持续扩大。此外，一些医疗机构还建立了独立的算法审计委员会，负责定期审查 AI 系统在临床应用中的公平性表现，并对可

能存在的伦理风险提出改进建议。

更进一步，全生命周期公平性审计还需要在制度层面建立透明化与问责机制。医疗 AI 系统一旦被广泛应用，其决策结果可能直接影响患者的诊疗机会与医疗资源分配。因此，模型的设计逻辑、训练数据来源以及性能评估结果应当在一定范围内保持透明，以便监管机构、医疗机构以及公众进行监督。例如，一些国家正在探索建立“算法影响评估”（Algorithmic Impact Assessment）制度，要求医疗 AI 系统在部署前提交公平性评估报告，并公开不同群体之间的性能差异指标。此外，在系统运行过程中，如果发现模型决策导致明显不公平后果，还应当具备追溯与责任界定机制，从而确保技术开发者、医疗机构以及监管机构能够共同承担治理责任。

综上所述，全生命周期公平性审计框架为解决医疗人工智能中的算法偏见问题提供了一种系统性路径。通过在数据采集、模型训练、系统部署以及长期运行各阶段建立持续的公平性评估与治理机制，医疗 AI 系统能够在不断进化的过程中保持对社会公平原则的敏感性。随着医疗大模型逐渐成为数字医疗体系的重要基础设施，这种跨学科、跨阶段的治理框架将成为保障人工智能伦理安全的重要支柱。只有在技术创新与伦理治理相互配合的前提下，医疗人工智能才能真正实现其最初的承诺——在提升医疗效率的同时，推动更加公平与包容的全球健康体系。

17.2 责任归属：当 AI 给出错误医疗建议，谁来负责？

随着大模型技术从后台的医疗文书整理、病历结构化抽取等行政辅助任务，迅速走向前台参与鉴别诊断、制定个性化治疗方案等核心临床决策，一个亟待解决且极其复杂的法理学黑洞浮出水面：当医疗 AI 生成了虚假的医学幻觉或给出了错误的治疗建议，并导致了真实的医疗损害时，应当由谁来承担这起悲剧的法律责任？是盲目信任算法的临床医生、开发这套不透明黑盒模型的科技巨头，还是急于降本增效而引进该系统的医疗机构？由于生成式 AI 的演进步伐远远超越了立法的速度，现有的法律体系尚未能为其量身定制匹配的监管规则，导致在问责机制上出现了巨大的真空与多方博弈。

17.2.1 “理性医师”标准下的临床医生责任悖论

在传统医疗过失侵权的法律框架中，医疗损害责任的认定通常围绕“标准护理义务”（Standard of Care）展开。所谓“理性医师标准”（Reasonable Physician Standard），是指一名在同等医疗资源条件与专业背景下、具备合理专业能力且保持谨慎态度的医生，在类似情境中应当采取的临床行为。换言之，法院在审理医疗纠纷时，并不会以事后结果为唯一标准，而是会考察医生在当时的医疗环境与知识条件下是否采取了合理、合规且符合专业共识的决策路径。在这一法律逻辑下，医生既不被要求做到绝对无误，也不需要具备超出常规水平的诊疗能力，只要其行为符合当时医学界普遍接受的专业实践规范，即可被认定为履行了合理的医疗义务。然而，随着医疗人工智能系统逐渐进入临床辅助决策领域，这一长期稳定的法律标准开始面临新的挑战。AI 系统的介入，使得临床决策不再完全依赖医生个人经验，而是逐渐演变为“人机协作”的复杂决策过程，这也使传统责任判定逻辑出现新的张力。

在当前美国乃至全球多数主流法院系统的审判实践中，人工智能系统通常不会被视为独立的法律责任主体。无论医疗大模型的底层神经网络结构多么复杂，算法推理链条多么难以解释，法律仍然倾向于将其视为一种工具性技术，而非具有独立判断能力的决策主体。因此，一旦 AI 辅助诊断系统参与临床决策并最终导致误诊或治疗失误，法律责任往往仍然归属于使用该系统的临床医生。在这一逻辑下，医生被要求在使用 AI 工具时保持足够的专业判断能力，即使 AI 系统给出了明确的诊疗建议，医生仍然必须对其进行独立评估。如果医生在未进行充分审查的情况下盲目依赖 AI 输出结果，一旦产生医疗损害，法院可能认定其违反了合理医疗标准。例如，在影像诊断场景中，如果 AI 系统错误地将某一病灶判定为良性，而医生完全依赖这一结论并忽视其他临床证据，那么法律可能认定医生未尽到独立审查义务，从而承担主要责任。这一法律立场在很大程度上体现了医疗体系对“人类最终责任者”的坚持，即便技术系统已经具备高度复杂的分析能力，法律仍然倾向于将决策责任保留在人类医生身上。

然而，这种责任归属模式在实践中逐渐形成一种明显的责任悖论。一方面，医疗 AI 系统被宣传为能够显著

提升诊断准确率、减少医生认知负担并优化医疗资源配置的先进工具；另一方面，在法律层面，医生却必须对 AI 建议保持高度怀疑态度，并承担最终决策风险。这意味着，医生在实际工作中既被鼓励使用 AI 系统以提高效率，又必须承担因使用该系统而产生的潜在法律责任。如果医生过度依赖 AI 系统，可能被指控缺乏独立判断；但如果医生完全忽视 AI 建议，也可能在未来被认为未充分利用可用技术资源。随着 AI 系统在医疗领域的普及，这种矛盾正在逐渐加剧。例如，如果某一 AI 系统在行业内被广泛证明能够显著降低漏诊率，那么医生在未使用该系统的情况下发生误诊，法院可能会认为其未采用当时可获得的最佳技术手段，从而构成所谓的“未使用过失”（Negligence for Non-use）。这种潜在责任风险使医生在面对 AI 技术时陷入一种两难境地：无论使用与否，都可能面临法律风险。

这一责任悖论还进一步改变了医疗实践中的决策结构。在传统医学模式下，医生的专业判断主要基于医学知识、临床经验以及患者个体情况；而在 AI 辅助医疗环境中，医生往往需要在自身判断与算法建议之间进行权衡。当二者结论一致时，决策过程相对顺畅，但当 AI 建议与医生经验发生冲突时，问题便变得复杂。如果医生坚持自己的判断而忽视 AI 建议，一旦结果证明 AI 更为准确，医生可能面临责任追究；反之，如果医生接受 AI 建议而忽视临床直觉，一旦 AI 出现错误，责任仍然可能落在医生身上。这种双重风险使医生在决策过程中不得不投入更多精力进行记录与解释，以证明其行为符合合理医疗标准。因此，在许多医疗机构中，医生开始通过更加详细的临床记录来保护自身，例如在病历中注明 AI 系统的建议内容、说明接受或拒绝该建议的理由，并记录最终决策的医学依据。这些文书记录在法律纠纷中往往成为关键证据，用以证明医生在决策过程中仍然保持了独立判断。

从制度发展的角度来看，“理性医师标准”在 AI 时代也可能发生逐渐演化。随着医疗人工智能技术不断成熟，社会对合理医疗行为的期待也在改变。如果某一 AI 系统在大规模临床实践中被证明能够稳定提升诊断准确率，那么未来的医疗标准可能会逐渐将“合理使用 AI 辅助工具”纳入专业规范之中。这意味着，医生不仅需要具备传统医学知识，还需要理解并合理使用人工智能系统。例如，一些医学协会已经开始讨论制定 AI 使用指南，明确医生在不同临床情境下应如何参考 AI 建议，以及在何种情况下可以合理忽略算法结果。通过这种方式，医疗 AI 系统将逐渐从“可选辅助工具”转变为“标准医疗实践的一部分”。然而，在这一转变过程中，如何平衡医生自主判断与技术辅助之间的关系，仍然是法律与医学界需要持续讨论的重要问题。

总体而言，医疗人工智能的引入正在重塑传统医疗责任体系。法律体系一方面坚持医生作为最终责任主体的原则，另一方面又逐渐认可 AI 系统在医疗决策中的重要作用。在这种双重逻辑下，医生既需要利用 AI 工具提高诊疗效率，又必须保持足够的独立判断能力以承担法律责任。未来，随着 AI 技术在医疗领域的进一步普及，医疗法律体系可能需要发展出更加细致的责任分配机制，以在保障患者权益的同时，为医疗技术创新提供稳定的制度环境。

17.2.2 医疗器械监管与产品责任法的摇摆

从更加宏观的法律救济视角审视，由医疗大模型引发的医疗损害纠纷往往处于传统医疗过失责任与产品责任法（Product Liability）之间的模糊地带。在经典医疗法律体系中，患者通常通过“医疗过失侵权”途径寻求赔偿，即证明医生在诊疗过程中未履行合理的医疗标准，从而导致损害发生。然而，当医疗人工智能系统参与甚至影响临床决策时，损害的根源可能不再完全来自医生个人判断，而可能源自技术系统本身的设计缺陷、训练数据偏差或算法逻辑错误。在这种情况下，患者可能尝试通过产品责任法追究技术开发者的责任。若一款具备辅助诊断或治疗建议功能的医疗大模型被监管机构正式认定为“医疗器械软件”（Software as a Medical Device, SaMD），并且调查显示医疗事故源于系统本身存在不可预见的设计缺陷，或者开发商未对已知算法偏差和适用人群限制履行充分警示义务，那么患者在起诉医生或医疗机构的同时，也可能依据产品责任法向软件开发商或技术供应商提出索赔。与传统过失责任不同，在某些司法体系下，产品责任甚至可能采用严格责任原则（Strict Liability），即只要产品缺陷被证明与损害存在因果关系，开发者就可能承担赔偿责任。

然而，在现实实践中，大多数医疗大模型并未被正式归类为医疗器械，而是以“临床决策支持系统”（Clinical Decision Support, CDS）或“信息参考工具”的名义存在。这种定位在监管层面为技术创新提供了更大的灵活空间，但同时也模糊了责任边界。许多生成式医疗 AI 系统仅通过自然语言交互向医生或患者提供医学信息、风险

提示或诊疗建议，而不直接触发医疗行为。由于系统并未被法律认定为医疗器械，其开发者通常无需通过严格的医疗器械审批流程，也不需要承担传统医疗设备制造商所面临的监管义务。这种“灰色地带”的监管状态，使得医疗 AI 系统在快速发展的同时，也带来了责任归属的不确定性。当系统输出的错误建议被医生采纳并导致医疗损害时，开发者往往可以辩称系统仅提供参考信息，最终决策仍然由医生作出，从而避免承担直接法律责任。

此外，软件开发企业通常通过用户许可协议（End User License Agreement, EULA）中的免责条款进一步降低潜在法律风险。在这些协议中，开发者往往明确声明系统输出仅用于教育或信息参考目的，而非正式医疗建议，并强调用户在使用系统时必须依赖专业医疗判断。通过这种法律设计，技术公司在形式上将最终决策责任转移给医疗机构和医生。对于医疗机构而言，这意味着在部署 AI 系统时需要自行承担更多风险评估义务，而医生在使用这些工具时也需要承担更高的法律谨慎责任。然而，对于普通患者而言，这种责任转移机制往往难以被充分理解。一旦医疗损害发生，患者在追究技术公司责任时往往需要面对复杂的合同条款与技术因果关系证明，从而大大提高了维权难度。

这种责任结构的不对称性，也使得患者在法律救济过程中面临显著障碍。首先，证明 AI 系统存在技术缺陷本身就具有较高门槛。医疗大模型的内部结构通常极其复杂，患者或其律师往往难以获取模型训练数据、算法结构或系统日志等关键证据，而这些信息通常掌握在技术公司手中。其次，即便能够证明 AI 系统在某些情况下提供了错误建议，仍然需要进一步证明医生在决策过程中对系统建议产生了依赖，并且这种依赖直接导致医疗损害。这种因果关系链条往往涉及多个技术与医学因素，使诉讼过程变得异常复杂。因此，在许多案例中，患者最终只能通过传统医疗过失路径起诉医生或医院，而技术公司则由于合同免责条款和技术复杂性而避免承担直接责任。

随着医疗人工智能系统逐渐深入临床实践，这种法律结构可能面临重新调整的压力。一些监管机构已经开始重新评估医疗 AI 产品的法律定位。例如，美国食品药品监督管理局（FDA）正在探索针对自适应算法的监管框架，以便对持续学习的医疗软件进行动态监管；欧盟的《人工智能法案》（AI Act）也提出将部分高风险医疗 AI 系统纳入严格监管范围。这些政策变化表明，未来医疗 AI 可能逐渐被纳入更明确的产品责任体系之中。同时，一些法律学者建议建立新的责任分配模式，例如通过强制保险制度或风险共担机制，使开发者、医疗机构与医生在不同层面承担相应责任。

总体而言，医疗大模型在产品责任法与医疗过失责任之间的法律定位仍然处于不断演化之中。当前的监管实践在鼓励技术创新与保护患者权益之间保持着微妙平衡，但随着医疗 AI 系统在临床决策中的作用不断增强，这种平衡可能难以长期维持。未来，法律体系需要在明确责任边界、加强监管透明度以及保障患者救济权利之间找到新的制度路径，以确保医疗人工智能的发展既能够推动医学进步，也不会削弱医疗体系的伦理与法律基础。

17.2.3 中国语境下的复合型侵权责任与制度探索

在中国特定的法律与社会治理语境下，医疗大模型的责任归属问题同样面临复杂而严格的条文适用环境。根据现行《中华人民共和国民法典》第 1165 条、第 1218 条等关于侵权责任与医疗损害责任的核心规定，医疗损害纠纷通常建立在医疗机构或医务人员存在过错并造成患者损害的前提之上。然而，当医疗大模型参与诊疗过程时，传统责任结构开始出现新的法律难题。从法律主体资格角度来看，生成式人工智能系统即使在交互层面表现出高度拟人化特征，在法律上仍然不具备民事主体地位，也不具有独立财产能力或独立承担民事责任的资格。因此，在中国法律体系中，医疗大模型本身不可能成为侵权诉讼的被告主体。换言之，当 AI 系统产生所谓的“医学幻觉”并间接导致误诊、延误治疗或错误医疗建议时，患者在法律上无法直接对 AI 系统提起诉讼，而必须通过既有的侵权责任框架，将责任追溯到人类或机构主体之上。这一制度安排在保持法律体系稳定性的同时，也使医疗 AI 纠纷呈现出高度复杂的责任传导结构。

结合中国独特的医疗损害责任制度，医疗大模型参与诊疗活动时的责任分配通常呈现出明显的“机构化定责”特征。与部分西方法律体系中强调医生个人责任不同，中国医疗侵权责任往往优先归属于医疗机构整体。这一制度安排源于医疗服务在中国通常以机构为核心组织形式进行提供，医务人员在法律上被视为医疗机构的工作人员，其行为在多数情况下被视为机构行为的延伸。因此，当患者因医生采纳 AI 系统建议而遭受损害时，侵

权责任通常首先由医疗机构承担。在诉讼实践中，患者往往直接起诉医院或诊疗机构，而非单独起诉医生个人。即便医生在诊疗过程中使用了 AI 辅助系统，法律也倾向于将该系统视为医疗机构配置的技术工具，其风险仍然由机构整体承担。这种制度设计在一定程度上简化了患者的维权路径，因为患者只需面对一个责任主体即可获得赔偿。然而，从医疗机构角度来看，这也意味着在引入医疗 AI 系统时需要承担更高的风险评估与技术审查义务。

在责任进一步追溯的层面，中国法律体系同样为医疗 AI 开发者承担责任预留了制度空间。当某些 AI 系统被国家药品监督管理局（NMPA）明确认定为医疗器械软件，并纳入医疗器械监管体系时，其法律属性便发生变化。一旦医疗事故被认定与该系统存在技术缺陷有关，患者便可以依据《产品质量法》或相关侵权责任条款向生产者或开发者提起产品责任诉讼。例如，如果 AI 系统在算法设计中存在明显缺陷、训练数据严重偏差或未对适用人群进行充分风险提示，那么开发者可能被认定未履行产品安全保障义务。在实践中，医疗 AI 纠纷往往会形成一种多层责任结构：医疗机构首先对患者承担赔偿责任，然后再通过内部责任追偿机制向技术供应商或系统开发者追究责任。这种责任传导模式既保持了医疗损害责任体系的稳定，也为技术企业承担合理责任提供了法律路径。然而，由于医疗 AI 系统的技术复杂性，证明事故原因来自算法缺陷往往需要专业鉴定机构进行技术评估，这在实际诉讼中仍然具有较高门槛。

除了传统侵权责任与产品责任之外，医疗 AI 还对患者知情同意权与医疗伦理责任结构产生了深远影响。在传统医疗关系中，医患关系通常被理解为一种基于专业信任的双边关系，医生有义务向患者解释诊疗方案并获得知情同意。然而，当 AI 系统参与诊疗过程后，这一关系逐渐转变为“医生—AI—患者”的多主体互动结构。如果医生在诊疗过程中使用 AI 系统生成诊疗建议，却未向患者充分说明系统的参与程度、潜在误差以及算法风险，那么患者的知情同意权可能受到侵害。尤其是在生成式医疗大模型参与问诊或健康咨询的情境下，患者往往难以判断其获得的建议究竟来自人类医生还是算法系统。如果医疗机构未对 AI 系统的使用方式进行明确说明，就可能被认定为违反医疗伦理原则。此外，在某些情况下，即使 AI 建议未直接造成身体损害，但如果其错误信息导致患者产生严重心理压力或做出错误健康决策，也可能构成独立的精神损害赔偿请求。这些新的法律问题表明，医疗人工智能不仅改变了医疗决策过程，也正在逐渐重塑医疗法律责任与伦理规范的结构。

面对此类法律滞后于技术发展的复杂局面，中国法律体系仍在不断探索适应性制度路径。一方面，监管机构正在逐步加强对医疗人工智能产品的分类管理，例如通过医疗器械注册制度对高风险 AI 系统进行严格审批，同时对低风险信息辅助系统保持一定创新空间。另一方面，医疗机构在引入 AI 技术时也开始建立更加完善的内部风险控制机制，例如设立 AI 技术评估委员会、建立算法使用规范以及加强医生对 AI 系统的培训。通过这些制度安排，中国医疗 AI 责任体系逐渐形成一种以医疗机构为核心、以技术企业为补充责任主体、并兼顾患者知情权保护的复合型治理模式。虽然这一体系仍处于不断演化之中，但它为医疗人工智能在中国语境下的安全应用提供了初步制度框架。

面对此种法律滞后于技术狂飙的被动局面，全球法学界正在积极呼吁构建适应新时代的治理体系。部分学者提出，应当根据医疗 AI 在具体临床场景中被赋予的“自治层级”（Autonomy Levels），建立一种动态评估的“阶梯式问责机制”。在 AI 仅作为文献辅助或病例摘要工具的低自治层级，责任由临床医生全权承担；而当 AI 进化为自主开具处方的高自治系统时，模型开发者应承担主要责任。此外，还有跨学者探索建立“共同企业责任”（Common Enterprise Liability）学说，或者由国家、行业协会与 AI 企业共同出资建立针对 AI 医疗事故的无过错补偿基金（No-fault liability models），以在激励前沿技术无畏创新与保障受害者能够获得及时、充分救济之间，寻求一条艰难但必要的法理平衡之路。